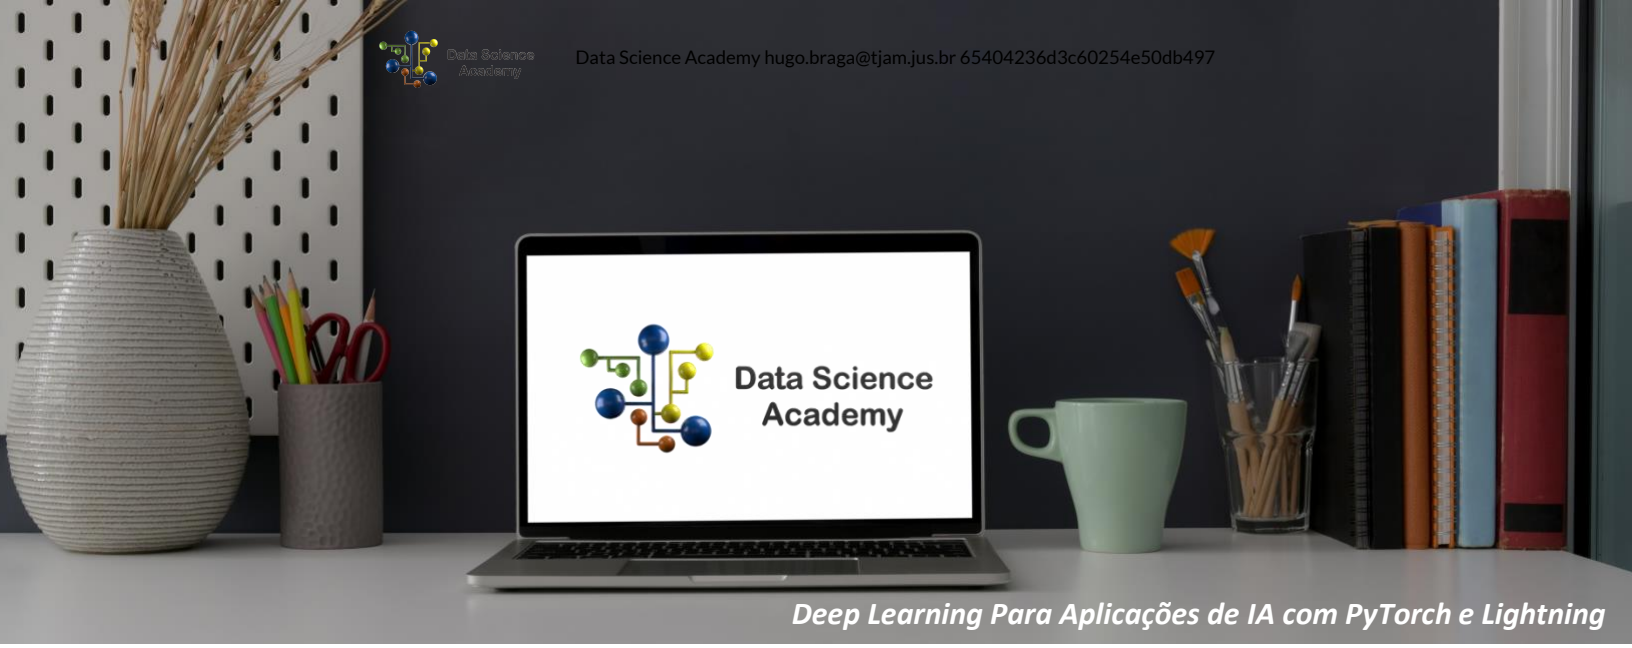

Data Science Academy hugo.braga@tjam.jus.br 65404236d3c60254e50db497

Deep Learning Para Aplicações de IA com PyTorch e Lightning

Matemática da Autoregressão

Para modelar dados com várias dimensões/características, os modelos autoregressivos precisam impor algumas condições.

Primeiro, o espaço de entrada X precisa ter uma ordenação determinante para seus recursos. É por isso que os modelos autoregressivos são normalmente usados para séries temporais que possuem uma sequência intrínseca de passos de tempo. Porém, eles podem ser empregados para imagens definindo, por exemplo, que os pixels da esquerda venham antes dos da direita e os de cima antes dos de baixo. Em segundo lugar, para modelar de maneira tratável a distribuição conjunta dos recursos em uma observação de dados (p(x)), a abordagem autoregressiva lança p(x) como um produto de distribuições condicionais.

Os modelos autoregressivos definem a distribuição conjunta usando condicionais sobre cada atributo, dados os valores dos atributos anteriores.

Por exemplo, a probabilidade de um pixel de uma imagem ter um valor de intensidade específico é condicionada pelos valores de todos os pixels anteriores; e a probabilidade de uma imagem (a distribuição conjunta de todos os pixels) é a combinação da probabilidade de todos os seus pixels.

Portanto, os modelos autoregressivos usam a regra da cadeia para decompor a verossimilhança da amostra de dados x em um produto de distribuições unidimensionais (equações abaixo). A fatoração transforma o problema de modelagem conjunta em um problema de sequência, onde se aprende a prever o próximo pixel dados todos os pixels gerados anteriormente.

$$p(\boldsymbol{x}) = p(x_1, x_2, \dots, x_n)$$

$$p(\boldsymbol{x}) = p(x_1)p(x_2) \dots p(x_n)$$

$$p(\boldsymbol{x}) = \prod_{i=1}^{n} p(x_i)$$

$$\underbrace{p(x)}_{\text{Likelihood of image } \boldsymbol{x}} = \prod_{i=1}^{n} \underbrace{p(x_i | x_1, \dots, x_{i-1})}_{\text{Probability of i'th pixel value given all previous pixels}}$$

Essas condições (ou seja, determinar a ordenação e o produto da distribuição condicional) são o que define principalmente um modelo autoregressivo.

Agora, o grande desafio é calcular essas verossimilhanças condicionais. Como definir essas distribuições complexas em um modelo expressivo, mas também tratável e escalável? Uma solução é usar aproximadores universais, como redes neurais profundas.

Referência:

Conditional Image generation with PixelCNN decoders
https://arxiv.org/pdf/1606.05328.pdf