Data Science Academy hugo.braga@tjam.jus.br 65404236d3c60254e50db497

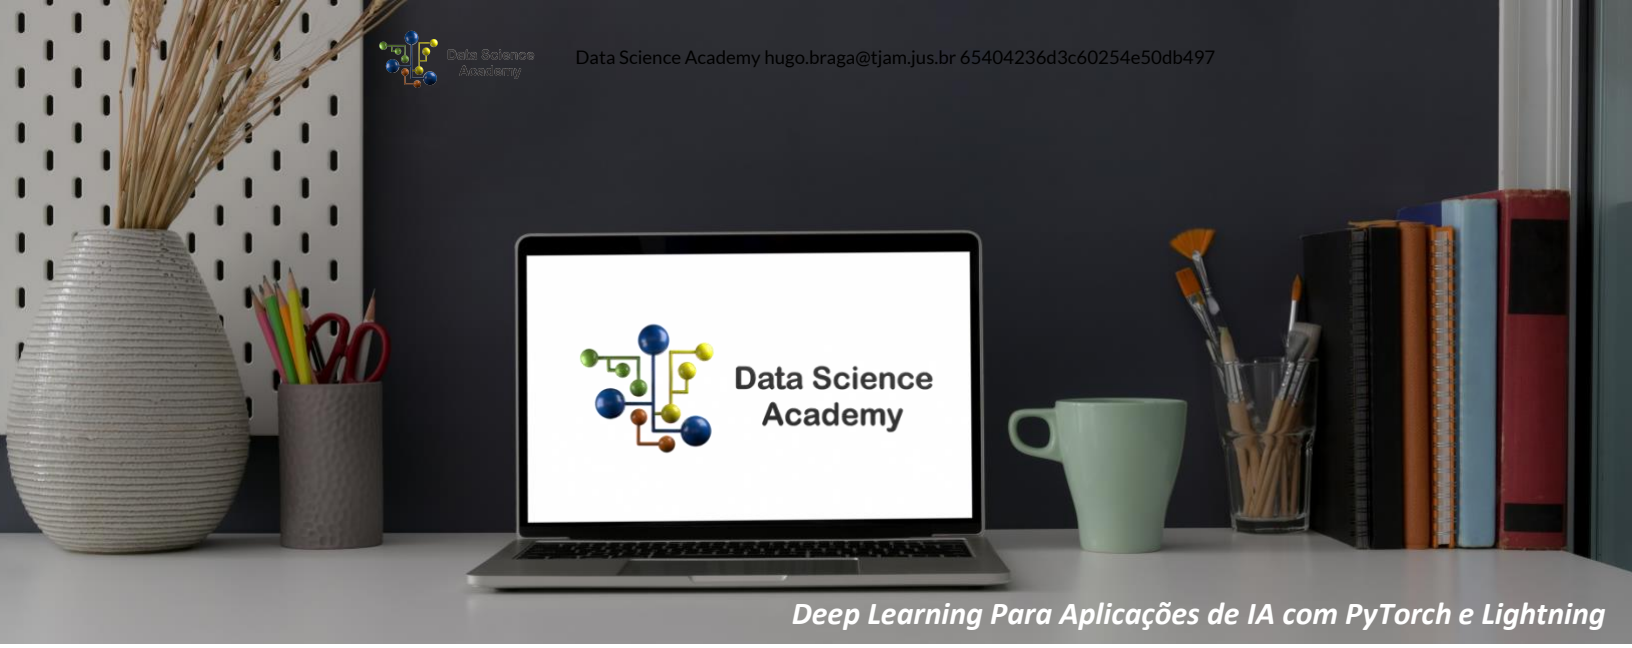




# Deep Learning Para Aplicações de IA com PyTorch e Lightning

# Por Que Usamos Batch Normalization no Modelo DCGAN?

Batch Normalization é uma técnica usada em Deep Learning para estabilizar e acelerar o aprendizado das redes neurais. A técnica foi introduzida em um artigo de 2015 por Sergey Ioffe e Christian Szegedy.

Batch normalization padroniza as entradas para cada camada de tal maneira que tenham média zero e variância unitária. Isso é realizado calculando a média e a variância do batch de dados que passam por uma camada e, em seguida, normalizando os dados com esses valores. A normalização é seguida por uma operação de escalonamento e deslocamento, que permite que a camada aprenda a melhor distribuição dos seus dados.

Os benefícios da batch normalization incluem:

**Acelera o treinamento**: ao normalizar as entradas para cada camada, a batch normalization ajuda a mitigar o problema do desaparecimento do gradiente, o que pode retardar o treinamento de redes neurais profundas.

**Permite uma maior taxa de aprendizado**: sem batch normalization, as redes neurais podem ser sensíveis à escolha da taxa de aprendizado. Uma taxa de aprendizado muito alta pode levar a explodir gradientes, enquanto uma taxa muito baixa pode levar a um treinamento muito lento. A batch normalization ajuda a mitigar esses problemas.

**Atua como uma forma de regularização**: a batch normalization adiciona um pouco de ruído aos dados de entrada de cada camada. Isso pode ter um efeito de regularização, semelhante ao dropout.

No contexto das DCGANs (Deep Convolutional Generative Adversarial Networks), a batch normalization é especialmente importante. GANs podem ser difíceis de treinar e uma das razões é que os gradientes que fluem de volta através do gerador e do discriminador durante o treinamento podem oscilar muito. Essas oscilações podem levar a um treinamento instável e a geradores que produzem amostras de má qualidade.

A batch normalization pode ajudar a estabilizar o treinamento, garantindo que os valores alimentados através das camadas do gerador e do discriminador tenham uma distribuição mais estável. Isso pode resultar em gradientes mais estáveis e, por fim, em um treinamento mais estável. Além disso, a batch normalization pode permitir que cada camada da GAN aprenda por si mesma um pouco mais independentemente das outras camadas.

Leia mais sobre a técnica no paper da pesquisa original:

https://arxiv.org/abs/1502.03167