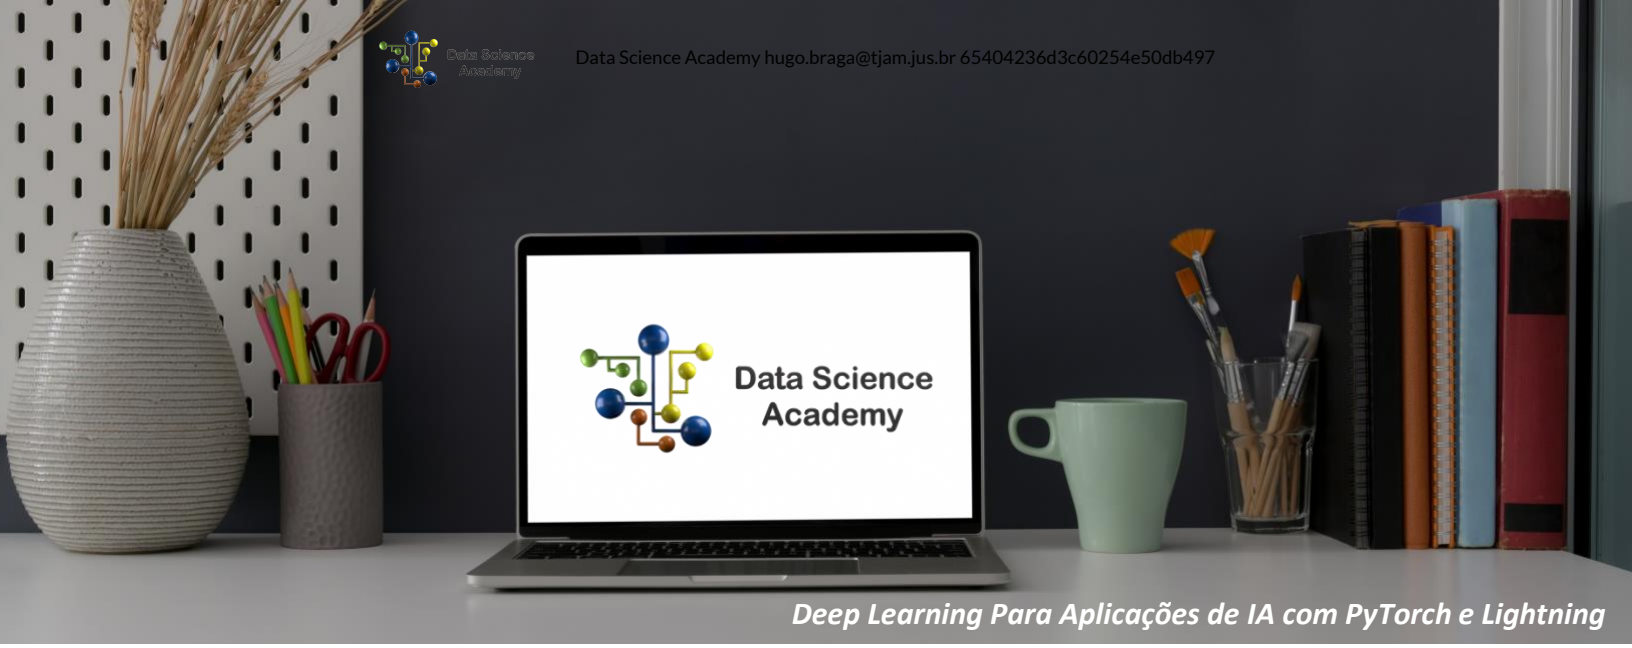

Data Science Academy hugo.braga@tjam.jus.br 65404236d3c60254e50db497

Deep Learning Para Aplicações de IA com PyTorch e Lightning

Estudo de Caso 5
Matemática da Divergência Contrastiva (Contrastive Divergence)

Quando treinamos um modelo em modelagem generativa, geralmente é feito por estimativa de máxima verossimilhança. Em outras palavras, tentamos maximizar a verossimilhança dos exemplos no conjunto de treinamento.

Como a probabilidade exata de um ponto não pode ser determinada devido à constante de normalização desconhecida Z_θ, precisamos treinar modelos baseados em energia ligeiramente diferentes. Não podemos simplesmente maximizar a probabilidade não normalizada $\exp(-E_\theta(\mathbf{x}_{\text{train}}))$ porque não há garantia de que Z_θ permaneça constante, ou que $\mathbf{x}_{\text{train}}$ está se tornando mais provável do que os outros.

No entanto, se basearmos nosso treinamento na comparação da probabilidade de pontos, podemos criar um objetivo estável. Ou seja, podemos reescrever nosso objetivo de máxima verossimilhança onde maximizamos a probabilidade de $\mathbf{x}_{\text{train}}$ em comparação com um ponto de dados amostrado aleatoriamente de nosso modelo:

$$\begin{aligned}\nabla_\theta \mathcal{L}_{\text{MLE}}(\theta; p) &= -\mathbb{E}_{p(\mathbf{x})}\left[\nabla_\theta \log q_\theta(\mathbf{x})\right] \\ &= \mathbb{E}_{p(\mathbf{x})}\left[\nabla_\theta E_\theta(\mathbf{x})\right] - \mathbb{E}_{q_\theta(\mathbf{x})}\left[\nabla_\theta E_\theta(\mathbf{x})\right]\end{aligned}$$

Observe que a perda (função de erro) ainda é um objetivo que queremos minimizar. Assim, tentamos minimizar a energia para pontos de dados do conjunto de dados, enquanto maximizamos a energia para pontos de dados amostrados aleatoriamente de nosso modelo (como amostramos será explicado mais a frente neste capítulo).

Embora esse objetivo pareça intuitivo, como ele é realmente derivado de nossa distribuição original $q_\theta(\mathbf{x})$? O truque é que aproximamos Z_θ por uma única amostra de Monte-Carlo. Isso nos dá exatamente o mesmo objetivo escrito acima.

Visualmente, podemos olhar para o objetivo da seguinte forma:

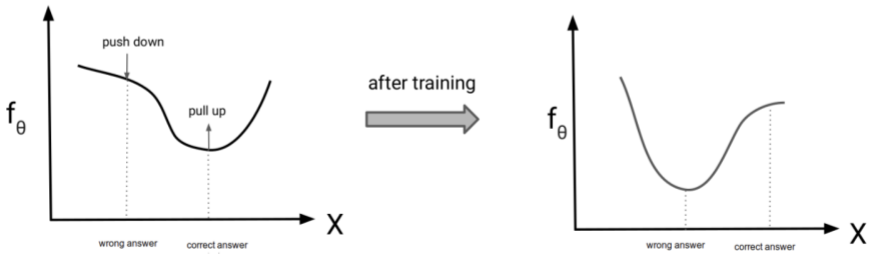

f_θ representa $\exp(-E_\theta(\mathbf{x}))$ no nosso caso. O ponto à direita, chamado "resposta correta", representa um ponto de dados do conjunto de dados (ou seja, x_{train}), e o ponto esquerdo, "resposta errada", uma amostra do nosso modelo (ou seja, x_{amostra}). Assim, tentamos "puxar para cima" a probabilidade dos pontos de dados no conjunto de dados, enquanto "empurramos para baixo" os pontos amostrados aleatoriamente.

As duas forças para puxar e empurrar estão em equilíbrio se $q_\theta(\mathbf{x}) = p(\mathbf{x})$.

Referência:

https://deepgenerativemodels.github.io/assets/slides/cs236_lecture11.pdf