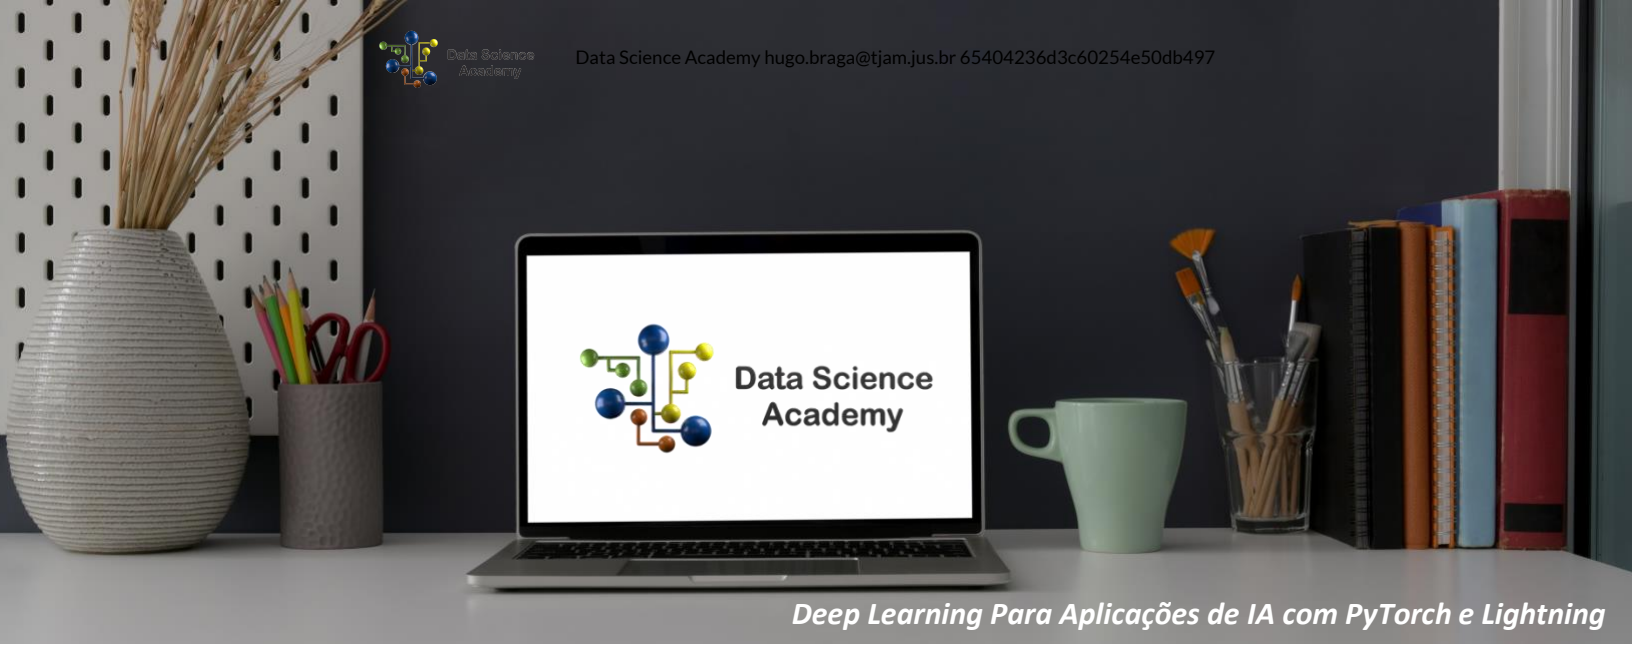

Data Science Academy hugo.braga@tjam.jus.br 65404236d3c60254e50db497

Deep Learning Para Aplicações de IA com PyTorch e Lightning

Graph Attention Network - GAT

A Graph Attention Network (GAT) é uma arquitetura de rede neural para trabalhar com dados estruturados em forma de grafo. Ela foi proposta em 2017 por Petar Veličković e colaboradores no artigo "Graph Attention Networks".

A GAT estende as técnicas convolucionais de grafos, como a Graph Convolutional Network (GCN), introduzindo mecanismos de atenção (similar aos Transformers) que permitem que a rede pese de forma adaptativa a importância das informações dos nós vizinhos.

A ideia principal por trás da GAT é calcular a importância relativa das arestas (ou seja, a relação entre dois nós) usando um mecanismo de atenção. Isso permite que a rede ajuste a importância de cada vizinho em relação ao nó central, em vez de tratar todos os vizinhos igualmente. A atenção é calculada com base nas características dos nós e é aprendida durante o treinamento da rede.

Aqui estão algumas das principais características da Graph Attention Network:

Mecanismo de Atenção: A GAT utiliza um mecanismo de atenção para calcular a importância relativa dos nós vizinhos. Isso permite que a rede pese de forma adaptativa a contribuição de cada vizinho com base nas características dos nós e nas informações contextuais.

Aprendizado dos Pesos de Atenção: Os pesos de atenção são aprendidos durante o treinamento, permitindo que a rede ajuste a importância dos nós vizinhos em função das tarefas de aprendizado específicas.

Atenção Multi-Cabeça: A GAT geralmente usa atenção multi-cabeça, o que significa que ela aprende múltiplos conjuntos de pesos de atenção para cada nó. Isso permite que a rede capture diferentes aspectos das informações contextuais e melhore a capacidade de generalização.

Invariância à Permutação: A GAT é invariante à permutação dos nós, o que significa que a ordem dos nós não afeta os resultados. Isso é importante para garantir a robustez e a generalização da rede.

Flexibilidade: A GAT é flexível e pode ser facilmente integrada a outras arquiteturas de redes neurais e aplicada a várias tarefas, como classificação de nós, classificação de grafos, previsão de ligações e muito mais.

A Graph Attention Network provou ser eficaz em várias tarefas de aprendizado de máquina em grafos e oferece uma abordagem poderosa e flexível para lidar com dados estruturados em forma de grafo.

Referência:

Graph Attention Networks
https://arxiv.org/abs/1710.10903