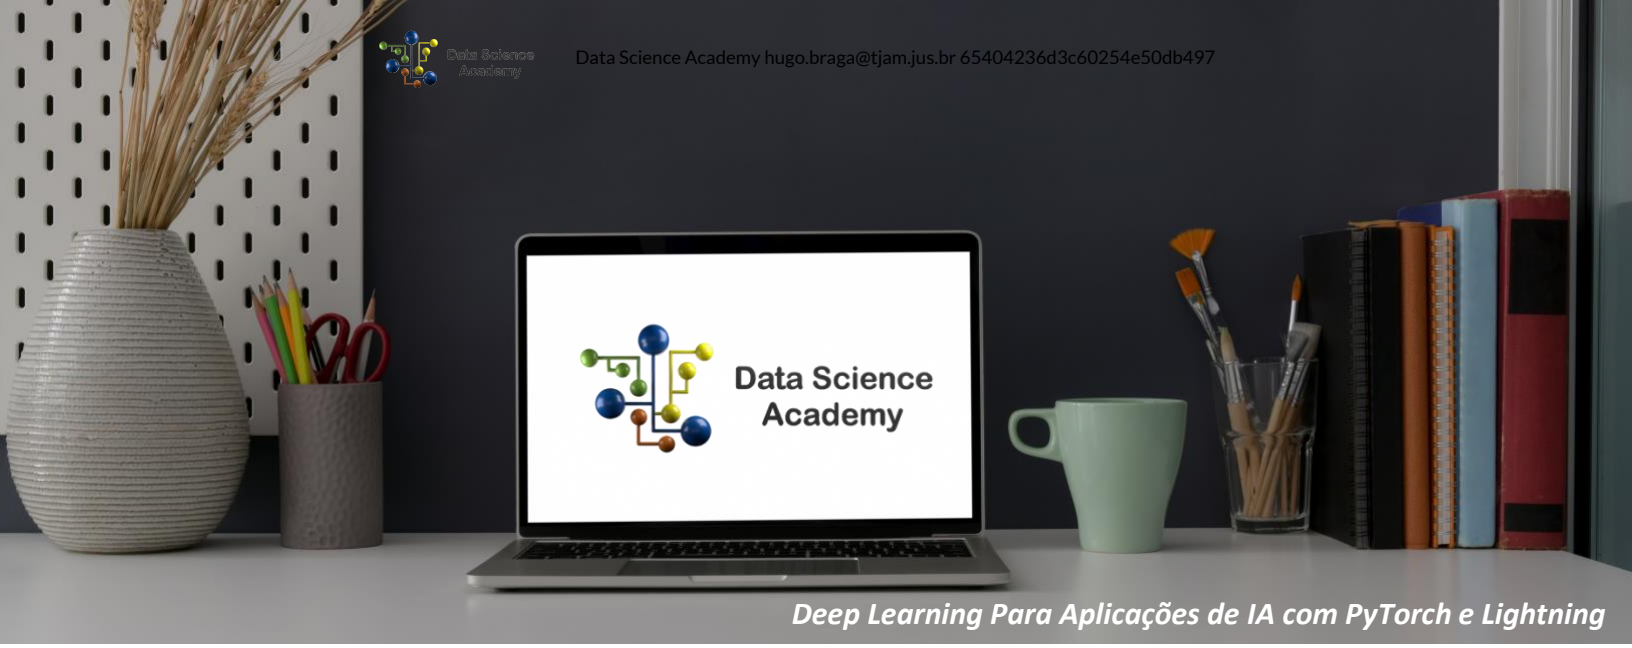

Data Science Academy hugo.braga@tjam.jus.br 65404236d3c60254e50db497

Deep Learning Para Aplicações de IA com PyTorch e Lightning

Matemática da Graph Attention Network e Funcionamento da Camada de Atenção

A Graph Attention Network (GAT) é um tipo de rede neural para aprendizado profundo em grafos que utiliza mecanismos de atenção para agregar informações dos vizinhos de cada nó de forma eficiente e adaptativa. A atenção permite que a GAT atribua pesos diferentes a cada vizinho com base na importância relativa de suas características. Vamos descrever a matemática por trás da GAT.

Dado um grafo G = (V, E), onde V é o conjunto de nós e E é o conjunto de arestas, a GAT busca aprender representações vetoriais para cada nó no grafo. Suponha que cada nó v_i tenha uma representação inicial $x_i \in R^F$ (onde F é a dimensão das características do nó). A GAT atualiza essas representações através de camadas de atenção.

Aqui estão as etapas básicas de uma única camada de atenção GAT:

Transformação Linear: Primeiro, as características de cada nó são transformadas linearmente usando uma matriz de pesos $W \in R^{(F' \times F)}$, onde F' é a dimensão desejada da nova representação do nó. Essa transformação resulta em uma nova representação h_i para cada nó v_i:

$$h_i = W * x_i$$

Cálculo das Pontuações de Atenção: Em seguida, a GAT calcula a pontuação de atenção (ou importância relativa) entre cada par de nós (v_i, v_j), onde v_j é um vizinho de v_i. A pontuação de atenção é calculada usando uma função de atenção a(., .), que é geralmente uma função simples como um produto escalar seguido por uma ativação LeakyReLU:

$$e_{ij} = a(h_i, h_j) = \text{LeakyReLU}(a' * (h_i \,||\, h_j))$$

Aqui, a' é um vetor de parâmetros a serem aprendidos e || indica a concatenação dos vetores h_i e h_j.

Normalização das Pontuações de Atenção: Para tornar as pontuações de atenção comparáveis e limitadas entre 0 e 1, aplica-se a função softmax às pontuações de atenção de cada nó e seus vizinhos:

$$\alpha_{ij} = \text{softmax}_j(e_{ij}) = \exp(e_{ij}) / \Sigma_k \exp(e_{ik})$$

Isso resulta em coeficientes de atenção normalizados α_{ij} para cada par de nós (v_i, v_j).

Agregação Ponderada dos Vizinhos: Com os coeficientes de atenção calculados, a GAT agora pode agregar as características dos vizinhos de cada nó, ponderadas pelos coeficientes de atenção:

$$h_i' = \Sigma_j \alpha_{ij} * h_j$$

Isso resulta em uma nova representação h_i' para cada nó v_i, que incorpora informações dos vizinhos ponderadas por suas importâncias relativas.

Ativação e Multi-Cabeça: Por fim, pode-se aplicar uma função de ativação (por exemplo, ELU) à nova representação do nó e também utilizar múltiplas "cabeças" de atenção para capturar diferentes aspectos das relações entre os nós. As representações resultantes das múltiplas cabeças são concatenadas ou somadas.

Referência:

https://arxiv.org/abs/1710.10903