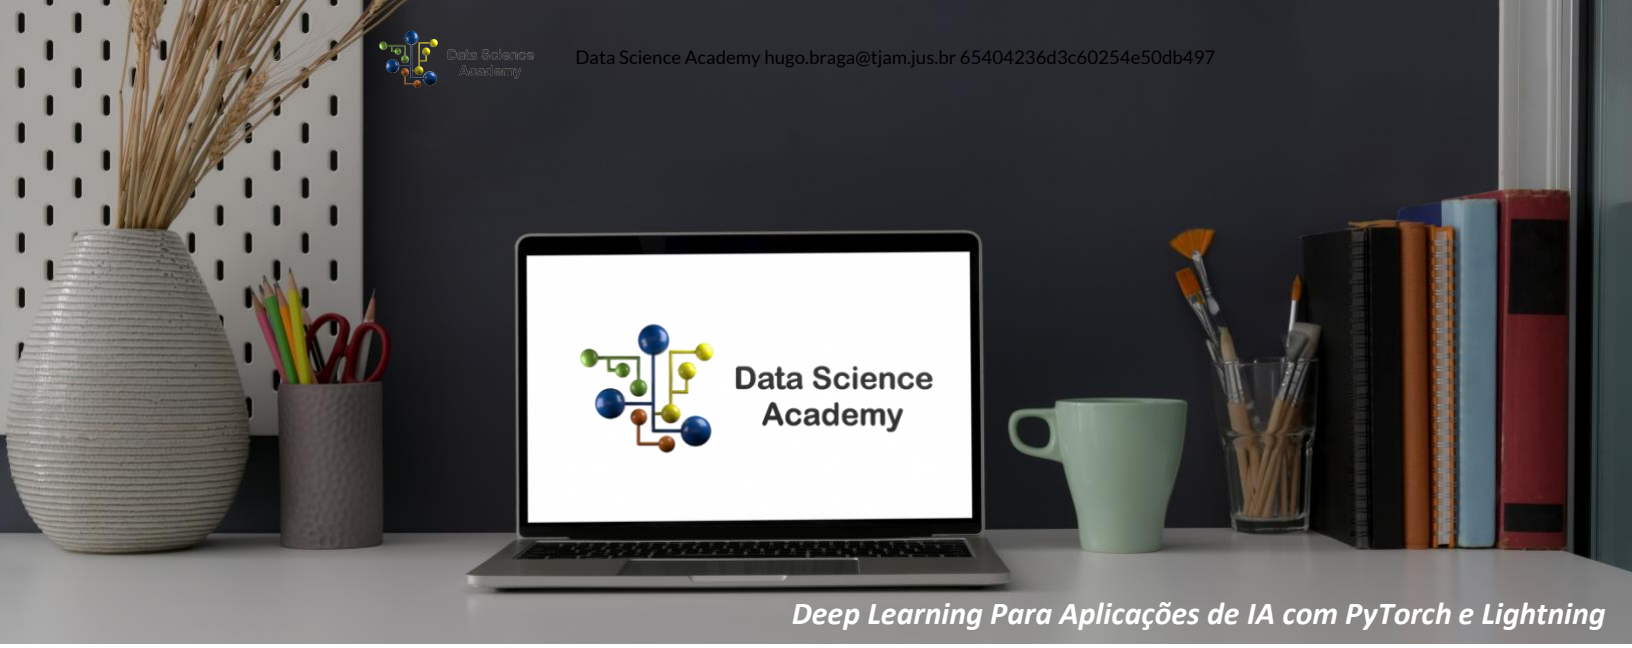

Data Science Academy hugo.braga@tjam.jus.br 65404236d3c60254e50db497

Deep Learning Para Aplicações de IA com PyTorch e Lightning

Arquitetura de Modelo LLM Baseada em Transformers

Os Large Language Models (LLMs), como o GPT-3 da OpenAI, são frequentemente baseados em uma arquitetura de rede neural chamada "Transformer". Esta arquitetura foi apresentada em um artigo de 2017 chamado "Attention is All You Need" por Vaswani et al. O Transformer usa um mecanismo chamado "attention" ou "atenção" para determinar quais partes de uma entrada de texto são mais relevantes para cada palavra que está sendo prevista. Recomendamos a leitura do paper de pesquisa:

https://arxiv.org/abs/1706.03762

Vamos descrever como a arquitetura do Transformer funciona:

Input Embeddings: O texto de entrada é tokenizado em unidades menores, como palavras ou subpalavras, e cada token é incorporado em uma representação vetorial contínua. Essa etapa de incorporação captura as informações semânticas e sintáticas da entrada.

Positional Encoding: A codificação posicional é adicionada às incorporações de entrada para fornecer informações sobre as posições dos tokens porque os transformadores não codificam naturalmente a ordem dos tokens. Isso permite que o modelo processe os tokens levando em consideração sua ordem sequencial.

Encoder: Com base em uma técnica de rede neural, o codificador analisa o texto de entrada e cria vários estados ocultos que protegem o contexto e o significado dos dados de texto. Múltiplas camadas de codificador constituem o núcleo da arquitetura do transformador. Mecanismo de auto-atenção e rede neural feed-forward são os dois subcomponentes fundamentais de cada camada do codificador.

Self-Attention Mechanism: A auto-atenção permite que o modelo pondere a importância de diferentes tokens na sequência de entrada calculando pontuações de atenção. Ele permite que o modelo considere as dependências e relacionamentos entre diferentes tokens de maneira sensível ao contexto.

Feed-Forward Neural Network: Após a etapa de auto-atenção, uma rede neural feed-forward é aplicada a cada token de forma independente. Essa rede inclui camadas totalmente conectadas com funções de ativação não lineares, permitindo que o modelo capture interações complexas entre tokens.

Decoder Layers: Em alguns modelos baseados em transformador, um componente decodificador é incluído além do codificador. As camadas do decodificador permitem a geração autorregressiva, onde o modelo pode gerar saídas sequenciais atendendo aos tokens gerados anteriormente.

Multi-Head Attention: Transformers geralmente empregam atenção multi-head, onde a auto-atenção é executada simultaneamente com diferentes pesos de atenção aprendidos. Isso

permite que o modelo capture diferentes tipos de relacionamentos e atenda a várias partes da sequência de entrada simultaneamente.

Layer Normalization: A normalização de camada é aplicada após cada subcomponente ou camada na arquitetura do transformador. Isso ajuda a estabilizar o processo de aprendizado e melhora a capacidade do modelo de generalizar em diferentes entradas.

Output Layers: As camadas de saída do modelo do transformador podem variar dependendo da tarefa específica. Por exemplo, na modelagem de linguagem, uma projeção linear seguida pela ativação SoftMax é comumente usada para gerar a distribuição de probabilidade sobre o próximo token.

A ideia básica é que o Transformer seja capaz de prestar atenção em diferentes partes do texto de entrada ao produzir sua saída, permitindo que ele capture os padrões complexos que são necessários para entender e gerar texto humano.
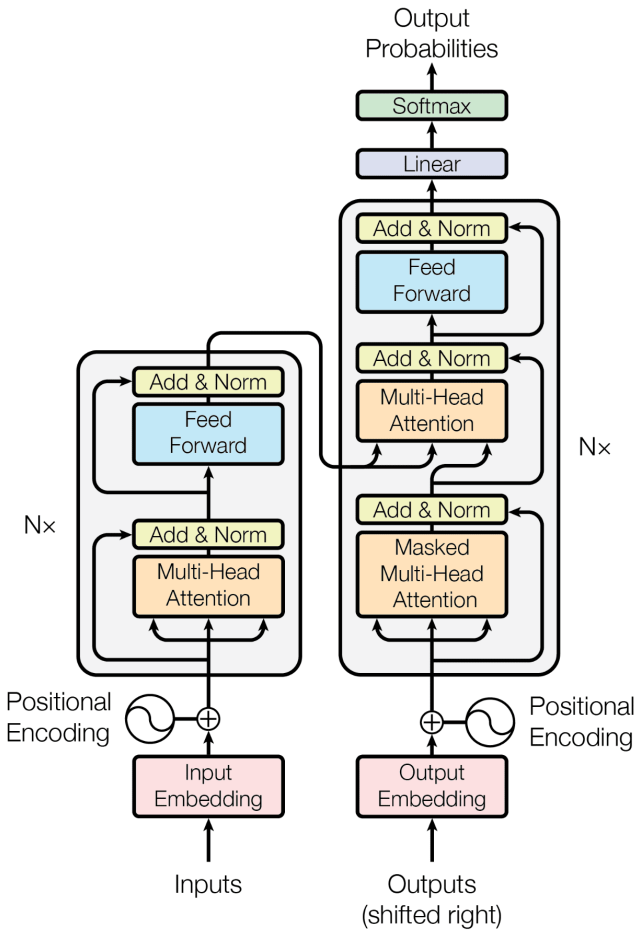
A imagem abaixo ilustra a arquitetura de um modelo Transformer: