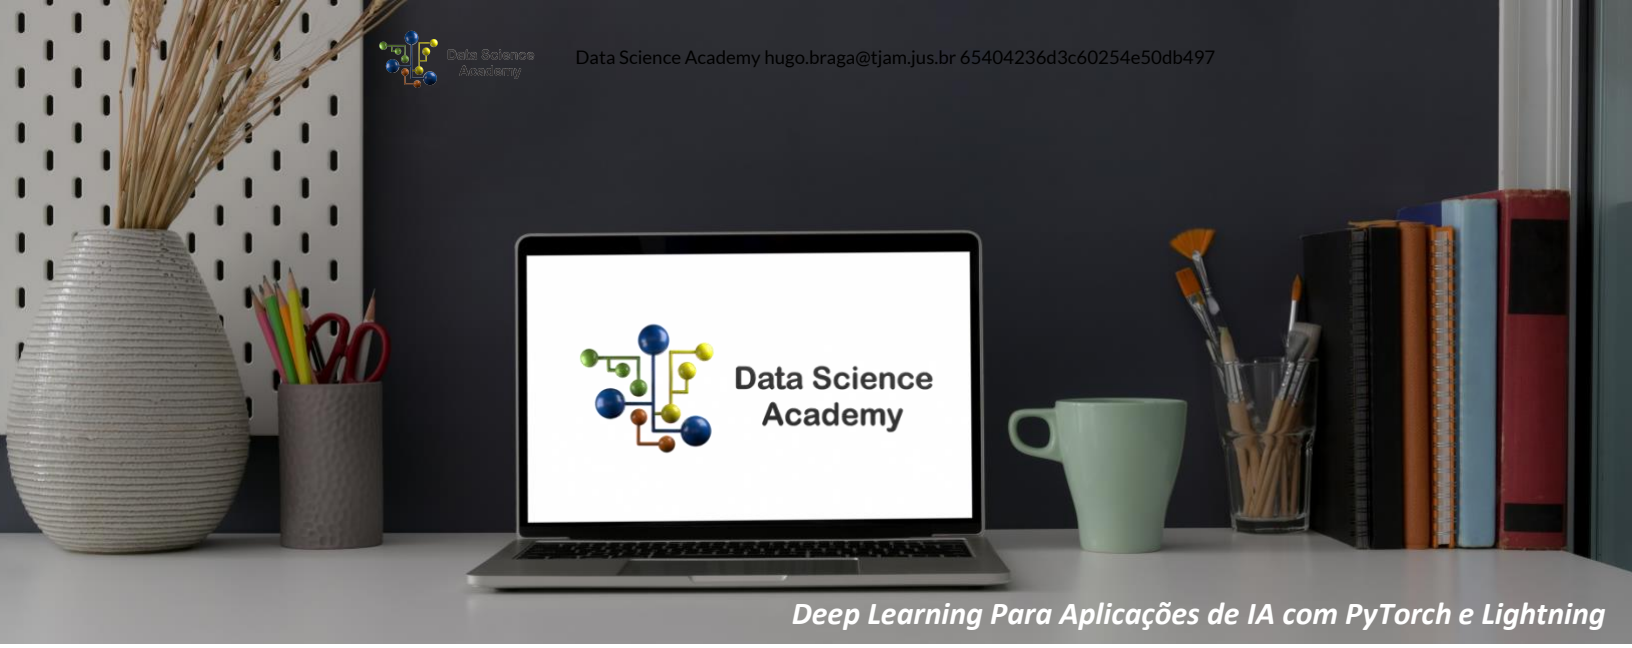

Data Science Academy hugo.braga@tjam.jus.br 65404236d3c60254e50db497

Deep Learning Para Aplicações de IA com PyTorch e Lightning

Arquitetura do Modelo Transformer

A arquitetura do modelo Transformer, introduzida por Vaswani et al. em 2017, é composta por duas partes principais: o codificador (encoder) e o decodificador (decoder). Ambos os componentes são construídos a partir de várias camadas idênticas, e o mecanismo de atenção é a principal inovação dessa arquitetura. Vamos analisar cada componente em detalhes:

Codificador (Encoder):

O codificador é responsável por processar a sequência de entrada e gerar uma representação vetorial contínua para cada token da sequência. Ele é composto por um número fixo de camadas idênticas e cada camada possui dois submódulos principais:

a. Mecanismo de Atenção por Produto Escalar (Self-Attention): Este mecanismo permite que o modelo considere a relação entre os tokens na sequência de entrada, atribuindo diferentes pesos às interações entre os tokens. Essencialmente, ele ajuda o modelo a entender a importância relativa de cada token em relação aos outros na sequência.

b. Rede Feed-Forward Posicional (Position-wise Feed-Forward Network): Esta é uma rede neural feed-forward totalmente conectada, que é aplicada a cada posição (token) separadamente e de forma idêntica. Sua função é agregar informações não lineares ao modelo e combinar características dos tokens.

Além disso, cada submódulo é seguido por uma normalização de camada (Layer Normalization) e conexões residuais para facilitar o treinamento.

Decodificador (Decoder):

O decodificador recebe a saída do codificador e gera a sequência de saída. Ele também é composto por um número fixo de camadas idênticas, mas com três submódulos principais:

a. Mecanismo de Atenção por Produto Escalar (Self-Attention): Semelhante ao usado no codificador, este mecanismo permite que o decodificador considere a relação entre os tokens na sequência de saída gerada até agora.

b. Atenção Entre Codificador-Decodificador (Encoder-Decoder Attention): Esta camada permite que o decodificador foque em diferentes partes da saída do codificador ao gerar a sequência de saída. Isso ajuda o decodificador a considerar as informações contextuais da sequência de entrada ao gerar a sequência de saída.

c. Rede Feed-Forward Posicional (Position-wise Feed-Forward Network): Semelhante à usada no codificador, esta rede agrega informações não lineares e combina características dos tokens.

O decodificador também usa normalização de camada e conexões residuais após cada submódulo.

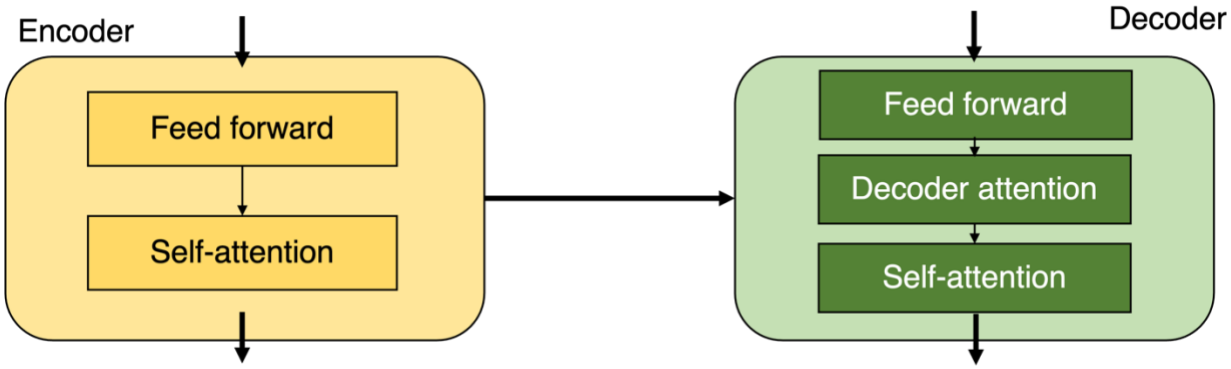

A arquitetura do Transformer também utiliza a "codificação posicional" para incorporar informações sobre a posição dos tokens na sequência, uma vez que o mecanismo de atenção não possui noção de ordem inerente.

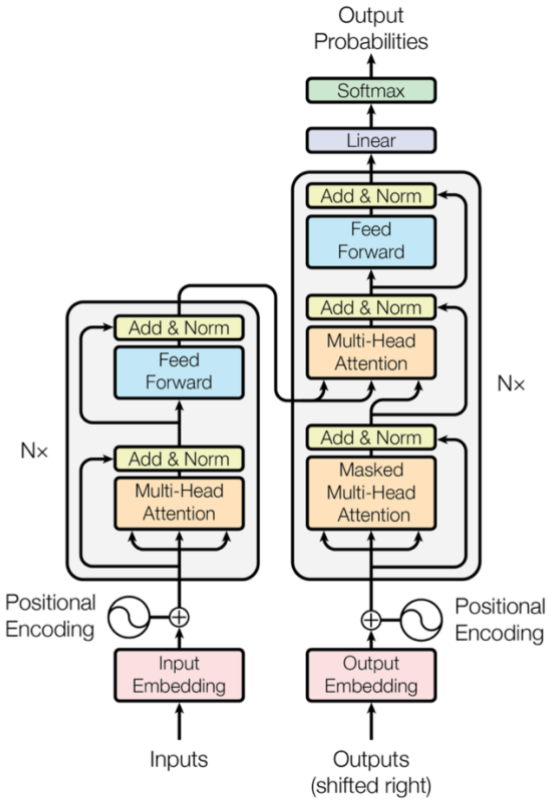

O Transformer é treinado para minimizar a perda de entropia cruzada entre as sequências de saída previstas e as sequências de saída verdadeiras. A arquitetura do Transformer tem sido a base de muitos modelos de processamento de linguagem natural de última geração, como BERT e a família GPT, alcançando resultados impressionantes em várias tarefas.

Recomendamos a leitura do artigo abaixo com mais detalhes sobre o uso da arquitetura Transformer nos modelos da família GPT:

https://blog.dsacademy.com.br/guia-de-introducao-aos-modelos-gpt/