Data Science Academy hugo.braga@tjam.jus.br 65404236d3c60254e50db497

Processamento de Linguagem Natural com Transformers

O Que é e Como Funciona Uma Rede Neural Recorrente?

Os humanos não começam a pensar do zero a cada segundo. Ao ler este texto, você entende cada palavra com base em sua compreensão das palavras anteriores. Você não joga tudo fora e começa a pensar de novo a cada palavra. Seus pensamentos têm persistência.

As redes neurais artificiais tradicionais não podem fazer isso, o que traz algumas limitações para esses tipos de modelos. Por exemplo, imagine que você queira classificar o tipo de evento que está acontecendo em todos os momentos de um filme. Não está claro como uma rede neural tradicional poderia usar seu raciocínio sobre eventos anteriores no filme para informar os posteriores.

Redes Neurais Recorrentes (RNNs) resolvem esse problema. São redes com loops, permitindo que as informações persistam.

As redes recorrentes são um tipo de rede neural artificial projetada para reconhecer padrões em sequências de dados, como texto, genomas, caligrafia, palavra falada ou dados de séries numéricas que emanam de sensores, bolsas de valores e agências governamentais. Esses algoritmos consideram tempo e sequência, eles têm uma dimensão temporal.

A pesquisa mostra que eles são um dos tipos mais poderosos e úteis de rede neural, juntamente com o mecanismo de atenção e as redes de memória. As RNNs são aplicáveis até mesmo a imagens, que podem ser decompostas em uma série de amostras e tratadas como uma sequência. As RNNs possuem loops, permitindo que as informações persistam.

Na figura abaixo vemos parte de uma rede neural convencional chamada A, processando algumas entradas xt e saídas ht. Um loop permite que as informações sejam passadas de uma etapa para a próxima.

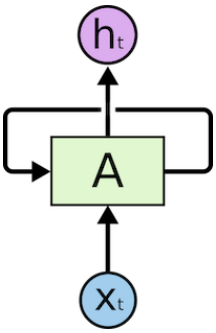

Uma Rede Neural Recorrente pode ser considerada como várias cópias da rede A na figura acima, cada rede passando uma mensagem para uma sucessora.

Considere o que acontece se desenrolarmos o loop:

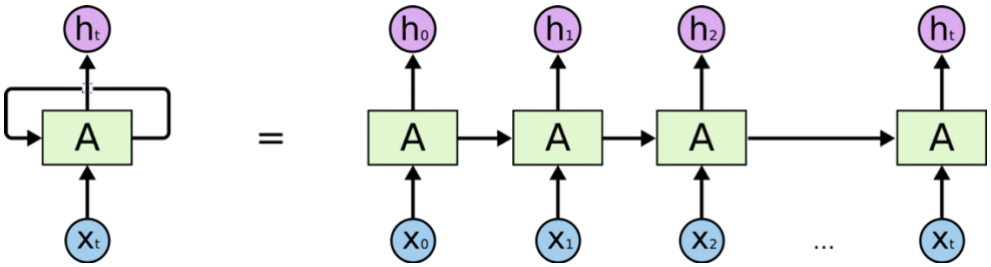

Essa natureza semelhante a uma cadeia mostra que as RNNs estão claramente relacionadas a sequências e listas. Dessa forma, se quisermos traduzir algum texto, podemos definir cada entrada como a palavra desse texto. A Rede Neural Recorrente passa as informações das palavras anteriores para a próxima rede que pode usar e processar essas informações.

A figura a seguir mostra a diferença entre a RNN e uma rede neural tradicional.

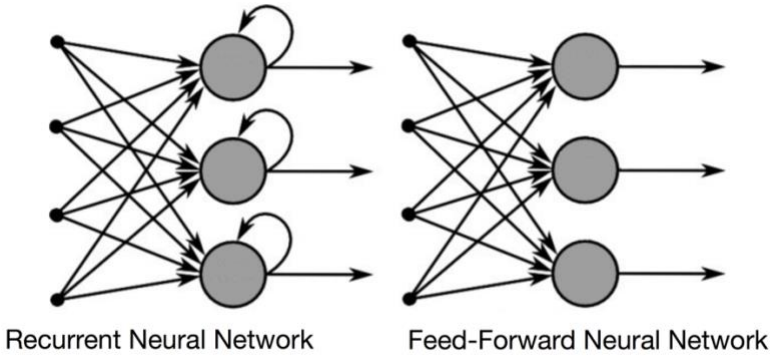

A decisão de uma rede recorrente alcançada na etapa de tempo t-1 afeta a decisão que alcançará um momento mais tarde na etapa de tempo t. Assim, as redes recorrentes têm duas fontes de entrada, o presente e o passado recente, que se combinam para determinar como respondem a novos dados, da mesma forma que fazemos na vida. Nas redes neurais recorrentes isso é feito, claro, com a ajuda da nossa querida Matemática.

As redes recorrentes são diferenciadas das redes feedforward pelo loop de feedback conectado às suas decisões anteriores, ingerindo suas próprias saídas momento após momento como entrada. Costuma-se dizer que as redes recorrentes têm memória. A adição de memória às redes neurais tem uma finalidade: há informações na própria sequência e as redes recorrentes a utilizam para executar tarefas que as redes de feedforward não conseguem.

Essa informação sequencial é preservada no estado oculto da rede recorrente, que consegue passar por muitas etapas de tempo à medida que ela avança em cascata para afetar o processamento de cada novo exemplo. Essas correlações entre eventos são separadas por muitos momentos, e essas correlações são chamadas de “dependências de longo prazo”, porque um evento no tempo depende e é uma função de um ou mais eventos que vieram antes.

Uma maneira objetiva de pensar sobre as RNNs é a seguinte: elas são uma forma de compartilhar pesos ao longo do tempo.

Assim como a memória humana circula invisivelmente dentro de um corpo, afetando nosso comportamento sem revelar sua forma completa, a informação circula nos estados ocultos de redes recorrentes. A língua portuguesa está cheia de palavras que descrevem os ciclos de feedback da memória. Quando dizemos que uma pessoa é assombrada por seus atos, por exemplo, estamos simplesmente falando sobre as consequências que as produções passadas causam no tempo presente. Os franceses chamam isso de "Le passé qui ne passe pas" ou "O passado que não passa".

Descreveremos o processo de levar a memória adiante matematicamente da seguinte forma:

$$\mathbf{h}_t = \phi\left(W\mathbf{x}_t + U\mathbf{h}_{t-1}\right),$$

O estado oculto na etapa de tempo t é ht. É uma função da entrada na mesma etapa de tempo xt, modificada por uma matriz de peso W (como a que usamos para redes feedforward) adicionada ao estado oculto do passo de tempo anterior ht-1 multiplicado por seu próprio estado oculto – para a matriz de estado oculto U, também conhecida como matriz de transição e semelhante a uma cadeia de Markov.

As matrizes de peso são filtros que determinam quanta importância deve ser dada tanto à entrada atual quanto ao estado oculto do passado. O erro que eles geram retornará por meio de retropropagação (backpropagation) e será usado para ajustar seus pesos até que o erro não diminua mais.

Como esse loop de feedback ocorre a cada etapa da série, cada estado oculto contém traços não apenas do estado oculto anterior, mas também de todos aqueles que precederam ht-1 pelo tempo que a memória pode persistir.

Dada uma série de letras, uma rede recorrente usará o primeiro caractere para ajudar a determinar sua percepção do segundo caractere, de tal forma que um q inicial possa levá-lo a inferir que a próxima letra será u, por exemplo.

A concepção geral das RNNs ajudou a definir a arquitetura dos Transformers, como veremos mais à frente.

Referências:

Recurrent Neural Networks (RNNs): A gentle Introduction and Overview
https://arxiv.org/pdf/1912.05911.pdf

Fundamentals of Recurrent Neural Network (RNN) and Long Short-Term Memory (LSTM) Network
https://arxiv.org/pdf/1808.03314.pdf