Data Science Academy hugo.braga@tjam.jus.br 65404236d3c60254e50db497

Processamento de Linguagem Natural com Transformers

Resolvendo Problemas das RNNs com as LSTMs

Ao organizar nossa agenda de tarefas para um dia da semana, priorizamos nossos compromissos. Se houver algo importante, podemos cancelar algumas das reuniões e acomodar o que é importante.

RNNs não fazem isso. Sempre que adiciona novas informações, transforma completamente as informações existentes, aplicando uma função. Toda a informação é modificada e não há consideração do que é importante e do que não é.

As redes LSTM (Long-Short Term Memory) são uma variação das RNNs, criadas para resolver alguns dos seus problemas. Essas redes têm pequenas modificações nas informações por meio de multiplicações e adições. Com LSTMs, a informação flui através de um mecanismo conhecido como estados de célula. Dessa forma, as LSTMs podem lembrar ou esquecer seletivamente coisas que são importantes e não tão importantes.

Internamente, uma LSTM se parece com o seguinte:

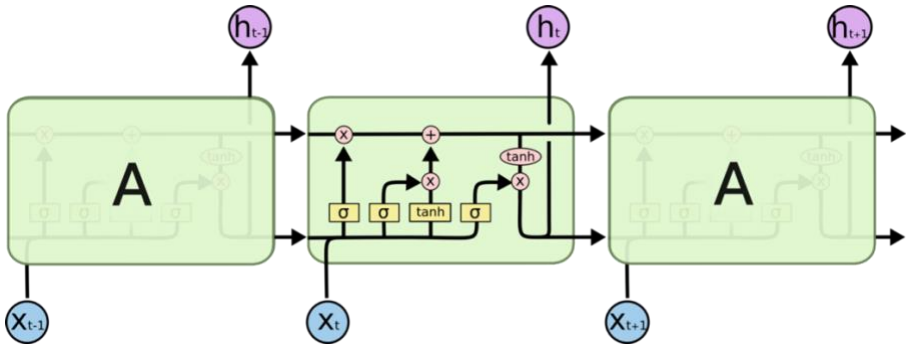

A LSTM é uma arquitetura de rede neural recorrente (RNN) que “lembra” valores em intervalos arbitrários. A LSTM é bem adequada para classificar, processar e prever séries temporais com intervalos de tempo de duração desconhecida. A insensibilidade relativa ao comprimento do gap dá uma vantagem à LSTM em relação a RNNs tradicionais (também chamadas “vanilla”), Modelos Ocultos de Markov (MOM) e outros métodos de aprendizado de sequências.

A estrutura de uma RNN é muito semelhante ao Modelo Oculto de Markov. No entanto, a principal diferença é como os parâmetros são calculados e construídos.

Uma das vantagens da LSTM é a insensibilidade ao comprimento do gap (intervalo). RNN e MOM dependem do estado oculto antes da emissão / sequência. Se quisermos prever a sequência após 1.000 intervalos em vez de 10, o modelo esqueceu o ponto de partida até então. Mas um modelo LSTM é capaz de “lembrar” por conta de sua estrutura de células, o diferencial da arquitetura LSTM.

A LSTM possui uma estrutura em cadeia que contém quatro redes neurais e diferentes blocos de memória chamados células.

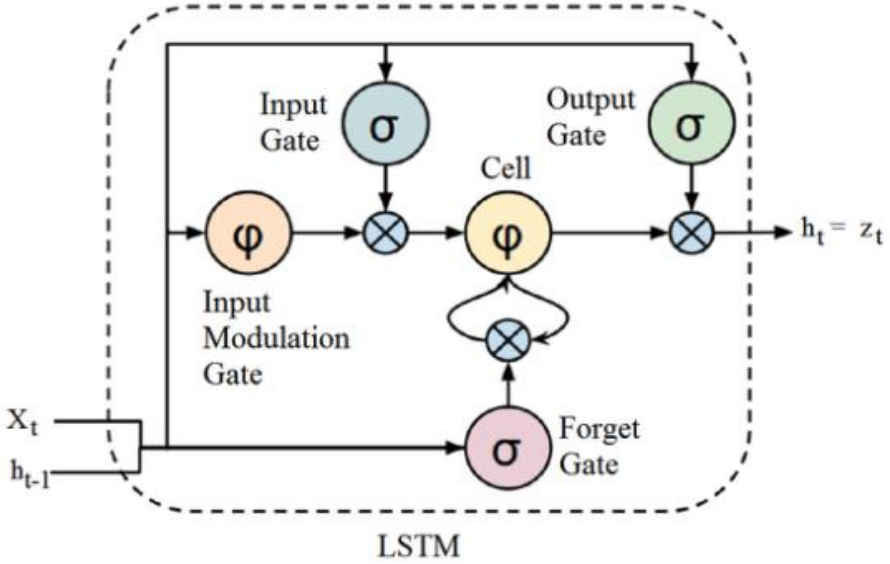

A informação é retida pelas células e as manipulações de memória são feitas pelos portões (gates). Existem três portões:

Forget Gate: As informações que não são mais úteis no estado da célula são removidas com o forget gate. Duas entradas: xt (entrada no momento específico) e ht-1 (saída de célula anterior) são alimentadas ao gate e multiplicadas por matrizes de peso, seguidas pela adição do bias. O resultante é passado por uma função de ativação que fornece uma saída binária. Se para um determinado estado de célula a saída for 0, a informação é esquecida e para a saída 1, a informação é retida para uso futuro.

Input Gate: A adição de informações úteis ao estado da célula é feita pelo input gate. Primeiro, a informação é regulada usando a função sigmoide que filtra os valores a serem lembrados de forma similar ao forget gate usando as entradas ht-1 e xt. Então, um vetor é criado usando a função tanh que dá saída de -1 a +1, que contém todos os valores possíveis de ht-1 e xt. Os valores do vetor e os valores regulados são multiplicados para obter as informações úteis

Output Gate: A tarefa de extrair informações úteis do estado da célula atual para ser apresentadas como uma saída é feita pelo output gate. Primeiro, um vetor é gerado aplicando a função tanh na célula. Então, a informação é regulada usando a função sigmóide que filtra os valores a serem lembrados usando as entradas ht-1 e xt. Os valores do vetor e os valores regulados são multiplicados para serem enviados como uma saída e entrada para a próxima célula.

A célula LSTM recebe duas entradas, a saída do último estado oculto e a observação no tempo = t. Além do estado oculto, não há informações sobre o passado para se lembrar. A memória de longo prazo é geralmente chamada de estado da célula. As setas em loop na imagem acima indicam a natureza recursiva da célula. Isso permite que as informações dos intervalos anteriores sejam armazenadas na célula LSTM. O estado da célula é modificado pelo forget gate colocado abaixo do estado da célula e também ajustado pela porta de modulação de entrada. Da equação, o estado da célula anterior forget, multiplica-se com a porta do esquecimento e adiciona novas informações através da saída das portas de entrada.

Algumas das famosas aplicações das LSTMs incluem:

- Modelagem de Linguagem
- Tradução de Idiomas
- Legendas em Imagens
- Geração de Texto
- Chatbots

As LSTMs funcionam muito bem, especialmente em problemas de séries temporais. Mas essa arquitetura apresenta um problema quando o volume de dados aumenta muito. Vejamos o que é esse problema e como o mecanismo de atenção (o diferencial dos Transformers) o resolveu.

Referências:

Recurrent Neural Networks (RNNs): A gentle Introduction and Overview
https://arxiv.org/pdf/1912.05911.pdf

Fundamentals of Recurrent Neural Network (RNN) and Long Short-Term Memory (LSTM) Network
https://arxiv.org/pdf/1808.03314.pdf