Data Science Academy hugo.braga@tjam.jus.br 65404236d3c60254e50db497

Processamento de Linguagem Natural com Transformers

O Problema com a LSTM

O mesmo problema que acontece com RNNs em geral, acontece com LSTMs, ou seja, quando as sentenças são muito longas, as LSTMs ainda não funcionam muito bem. A razão para isso é que a probabilidade de manter o contexto de uma palavra que está longe da palavra atual que está sendo processada diminui exponencialmente com a distância dela. Matematicamente isso tem um nome: "Vanishing Gradient".

O gradiente é um dos elementos dos cálculos de derivada que ocorrem na LSTM. À medida que a palavra necessária para compreender o contexto de outra palavra está mais distante em uma frase, o gradiente tende a ficar muito pequeno, bem próximo de zero praticamente "desaparecendo" ou "vanishing".

Isso significa que, quando as sentenças são longas, o modelo geralmente esquece o conteúdo de posições distantes na sequência. Outro problema com LSTMs é que é difícil paralelizar o trabalho de processamento de sentenças, já que você precisa processar palavra por palavra. Para resumir, LSTMs e RNNs apresentam 3 problemas:

- A computação sequencial inibe a paralelização.
- Não há modelagem explícita de dependências de longo e curto alcance.
- A "distância" entre as posições é linear.

E para resolver esses problemas os pesquisadores criaram o mecanismo de atenção!

Referências:

Recurrent Neural Networks (RNNs): A gentle Introduction and Overview
https://arxiv.org/pdf/1912.05911.pdf

Fundamentals of Recurrent Neural Network (RNN) and Long Short-Term Memory (LSTM) Network
https://arxiv.org/pdf/1808.03314.pdf