Data Science Academy hugo.braga@tjam.jus.br 65404236d3c60254e50db497

Processamento de Linguagem Natural com Transformers

O Mecanismo de Atenção

Para resolver alguns dos problemas descritos nas aulas anteriores, os pesquisadores criaram uma técnica para prestar atenção a palavras específicas.

Considere o ser humano. Ao traduzir uma frase, prestamos atenção especial à palavra que estamos traduzindo no momento. Quando estamos transcrevendo uma gravação de áudio, ouvimos atentamente o segmento que estamos escrevendo ativamente. E se você me pedir para descrever a sala em que estou sentado, darei uma olhada nos objetos que estou descrevendo enquanto o faço.

As redes neurais podem atingir esse mesmo comportamento usando a atenção, concentrando-se em parte de um subconjunto das informações que recebem.

O Mecanismo de Atenção é uma técnica utilizada em uma rede neural. Para RNNs, em vez de apenas codificar a frase inteira em um estado oculto, cada palavra tem um estado oculto correspondente que é passado até o estágio de decodificação. Em seguida, os estados ocultos são usados em cada etapa da RNN para decodificar. O diagrama abaixo ilustra a arquitetura de uma RNN do tipo LSTM com o Mecanismo de Atenção.

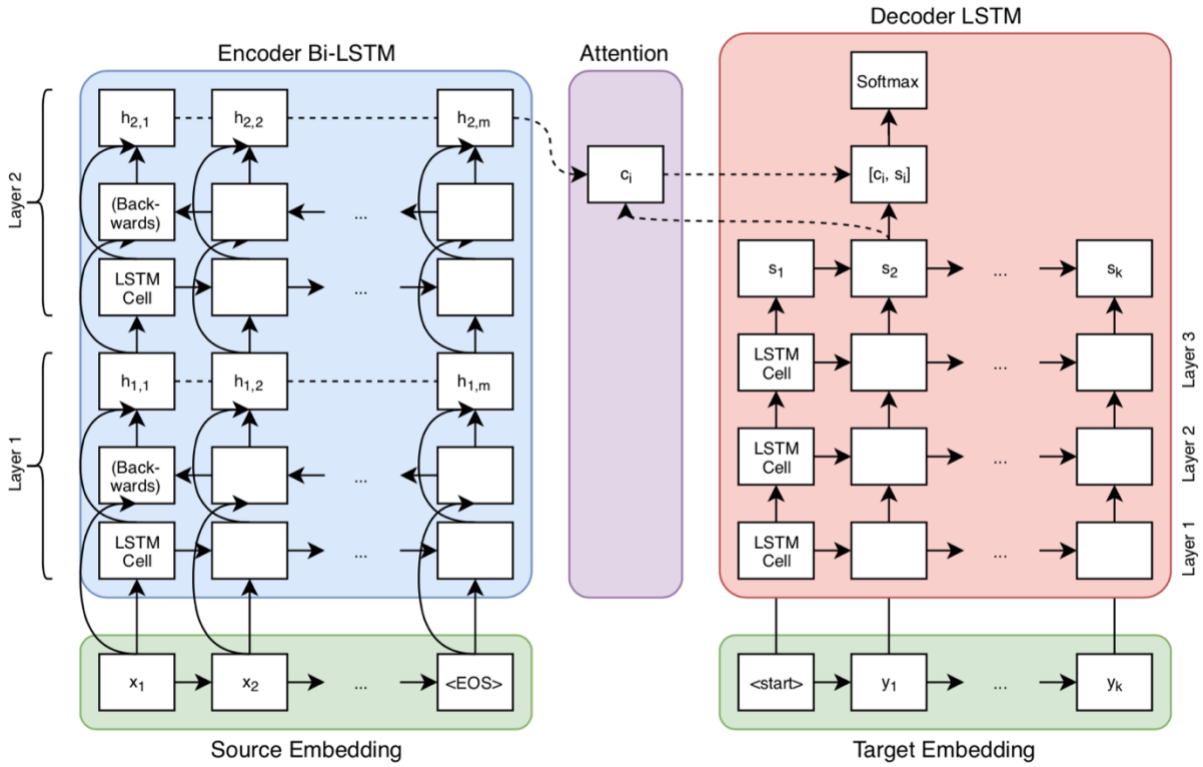

A ideia por trás dessa solução é que pode haver informações relevantes em cada palavra de uma frase. Então, para que a decodificação seja precisa, ela precisa levar em conta cada palavra da entrada, usando a atenção. Vamos compreender o papel do Encoder e do Decoder.

Encoder

A tarefa do codificador é fornecer uma representação da sentença de entrada. A sentença de entrada é uma sequência de palavras, para a qual primeiro consultamos a embedding matrix (a matriz de valores numéricos representando as palavras de um texto).

Então processamos essas palavras com uma rede neural recorrente. Isso resulta em estados ocultos que codificam cada palavra com seu contexto esquerdo, ou seja, todas as palavras precedentes. Para também obter o contexto certo, também construímos uma rede neural recorrente que corre da direita para a esquerda, ou mais precisamente, do final da frase para o começo. Ter duas redes neurais recorrentes sendo executadas em duas direções é chamado de rede neural recorrente bidirecional (Bi-LSTM, na imagem acima).

Decoder

O decodificador também é uma rede neural recorrente. É necessária alguma representação do contexto de entrada e o estado oculto anterior e a previsão da palavra de saída, e então gerar um novo estado de decodificador oculto e uma nova previsão de palavra de saída.

Se usarmos LSTMs para o codificador, então também usamos LSTMs para o decodificador. Do estado oculto agora prevemos a palavra de saída. Essa previsão assume a forma de uma distribuição de probabilidade sobre todo o vocabulário de saída. Se temos um vocabulário de, digamos, 50.000 palavras, então a predição é um vetor dimensional de 50.000, cada elemento correspondendo à probabilidade prevista para uma palavra no vocabulário.

O Mecanismo de Atenção

Com base no que foi descrito anteriormente, temos duas extremidades. O codificador nos deu uma sequência de representações de palavras hj = (← - hj, - → hj) e o decodificador espera um contexto ci em cada passo i. Agora descrevemos o mecanismo de atenção que une essas extremidades.

O mecanismo de atenção é difícil de visualizar usando os gráficos típicos de rede neural, mas a figura abaixo dá pelo menos uma ideia do que são as relações de entrada e saída antes de trabalharmos nas atividades práticas.

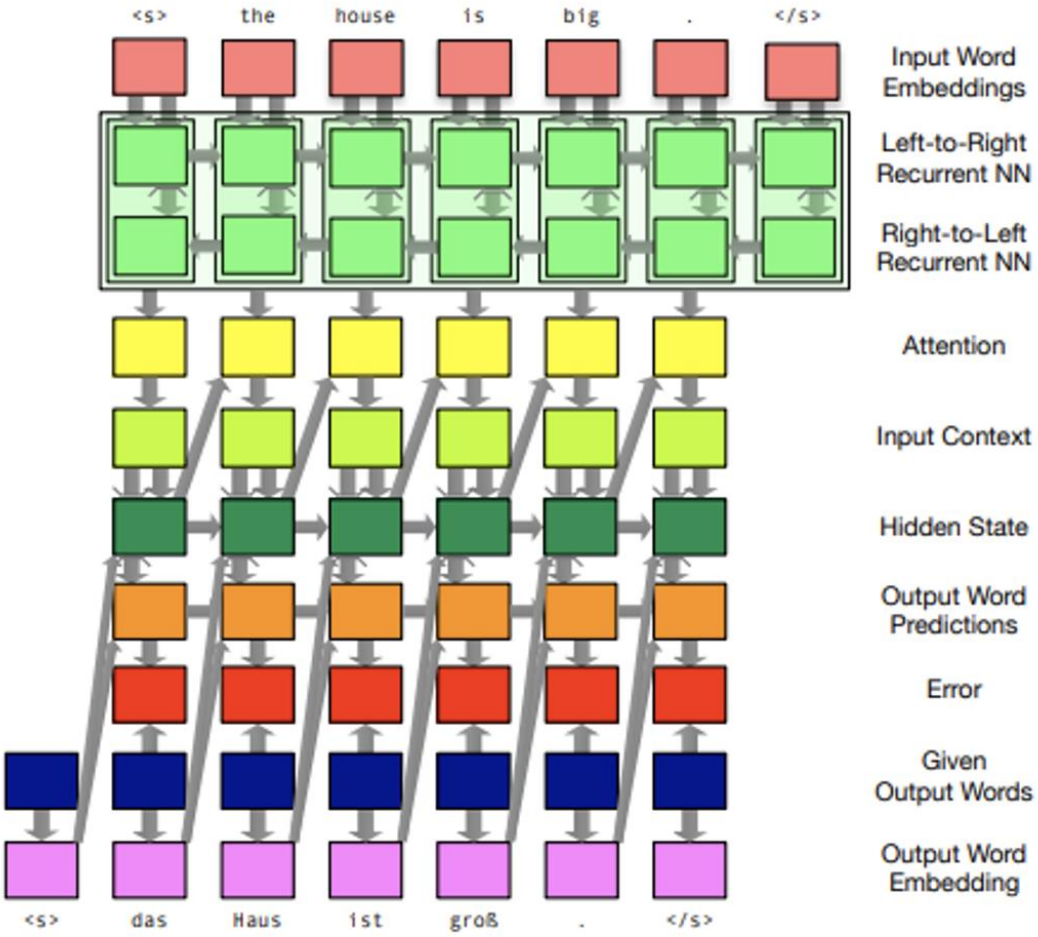

O mecanismo de atenção é informado por todas as representações de palavras de entrada (← - hj, - → hj) e pelo estado oculto anterior do decodificador si − 1, e produz um estado de contexto ci.

A motivação é que queremos calcular uma associação entre o estado do decodificador (que contém informações onde estamos na produção da sentença de saída) e cada palavra de entrada. Com base em quão forte é essa associação, ou em outras palavras, o quanto cada palavra de entrada é relevante para produzir a próxima palavra de saída, queremos ponderar o impacto da representação de palavras.

Mas alguns dos problemas que discutimos nas aulas anteriores ainda não foram totalmente resolvidos com Redes Neurais Recorrentes usando o Mecanismo de Atenção. Por exemplo, o processamento de entradas (palavras) em paralelo não é possível. Para um grande corpus de texto, isso aumenta o tempo gasto na tradução do texto. Os pesquisadores então pensaram, por que não usar uma Rede Neural Convolucional (CNN)?

Algumas das redes neurais mais populares para tradução de sequência, Wavenet e Bytenet, são Redes Neurais Convolucionais.

A razão pela qual as Redes Neurais Convolucionais podem funcionar em paralelo é que cada palavra na entrada pode ser processada ao mesmo tempo e não depende necessariamente das palavras anteriores a serem traduzidas.

Não apenas isso, mas a "distância" entre a palavra de saída e qualquer entrada para uma CNN é da ordem de log(N) — que é o tamanho da altura da árvore gerada da saída para a entrada (você pode ver isso na imagem abaixo). Isso é muito melhor do que a distância da saída de uma RNN e uma entrada, que é da ordem de N.

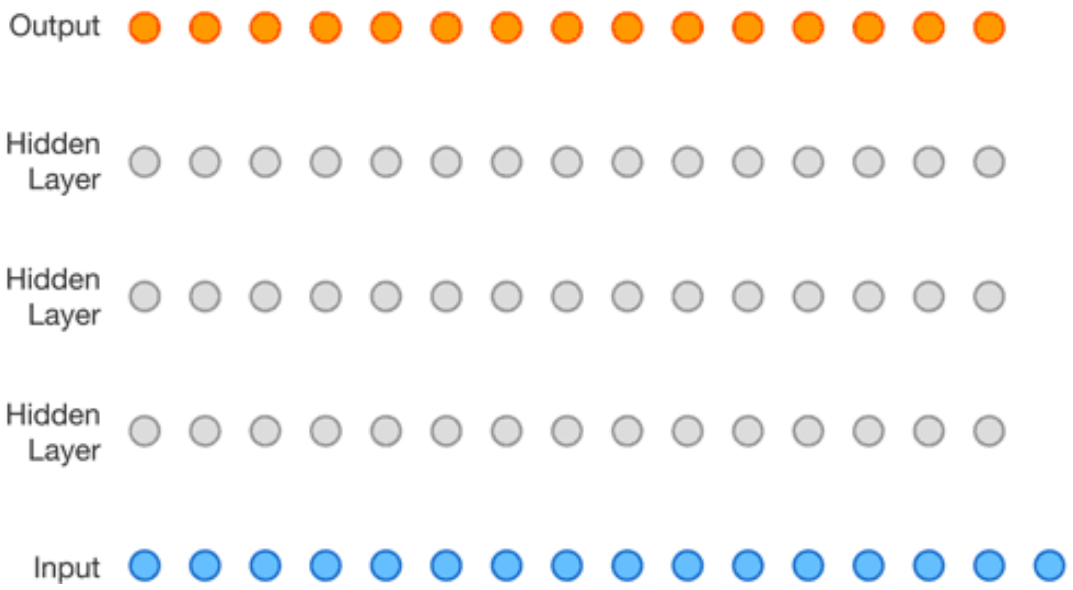

O problema é que as Redes Neurais Convolucionais não ajudam necessariamente com o problema de descobrir o problema de dependências ao traduzir sentenças. É por isso que os Transformers foram criados, eles são uma combinação de CNNs com o Mecanismo de Atenção.

Ou seja, o Transformer é a evolução de poderosas arquiteturas de Deep Learning, uma evolução natural das técnicas de Inteligência Artificial.

Depois de conhecer como chegamos aos Transformers, vamos agora estudar essa arquitetura em detalhes.

Referências:

The Unreasonable Effectiveness of Recurrent Neural Networks
http://karpathy.github.io/2015/05/21/rnn-effectiveness/

Understanding LSTM Networks
http://colah.github.io/posts/2015-08-Understanding-LSTMs/

Visualizing A Neural Machine Translation Model (Mechanics of Seq2seq Models With Attention)
https://jalammar.github.io/visualizing-neural-machine-translation-mechanics-of-seq2seq-models-with-attention/

The Transformer – Attention is all you need
https://mchromiak.github.io/articles/2017/Sep/12/Transformer-Attention-is-all-you-need